

چگونه می توان ساختار مولد و تفکیک کننده را کوانتمی کرد؟

بخشی از پروژه پایانی محاسبات کوانتمی ترم 4031
نام: کسری فولادی (گروه تک نفره)، شماره دانشجویی: 402442297

در این خلاصه نویسی از مقاله *QGAN* به توضیح اینکه چگونه می توان اجرای یک *GAN* را با استفاده از کامپیوتر کوانتمی پیاده سازی کرد می پردازیم. در ابتدا خود *GAN* ها را توصیف می کنیم یک شبکه مولد تخصصی متشکل از یک مولد و یک تفکیک کننده می باشد که مولد سعی می کند نمونه هایی بسازد که مشابه نمونه های حقیقی از دیتاست R باشد و هدف تفکیک کننده این است که نمونه های جعلی را از نمونه های واقعی شناسایی کند (برای مثال در مخزن پروژه یک GAN کلاسیک و یک QGAN ترکیبی از کوانتمی و کلاسیک پیاده سازی شده است).

حالا اگر بخواهیم این ساختار این ها را کوانتمی کنیم می توانیم فرض کنیم که مولد (G) و دیتاست (R) مدار های کوانتمی پارامتری هستند که یک ورودی میگیرند و یک خروجی برحسب یک توضیح احتمالاتی می دهند و تفکیک کننده یک نمونه را ورودی می گیرد و یکی از دو خروجی زیر را می دهد.

$|\text{real}\rangle, |\text{fake}\rangle$

برای ساختار G فرض کنیم علاوه بر پارامتری که دریافت می کند یک برچسب لامبدا و یک بردار اضافی زد دریافت می کند و یک ماتریس چگالی مانند زیر خروجی می دهد.

$|\mathbf{z}\rangle, |\lambda\rangle$

برای ساختار R فرض کنیم علاوه بر پارامتری که دریافت می کند یک برچسب لامبدا کند و یک ماتریس چگالی مانند زیر خروجی می دهد.

$|\lambda\rangle$
 $R(|\lambda\rangle) = \rho_{\lambda}^R$

G علاوه بر پارامتر نتای جی که دریافت می کند یک برچسب لامبدا و یک بردار اضافی زد دریافت می کند و یک ماتریس چگالی مانند زیر خروجی می دهد، بردار نویز z می تواند دو نقش متفاوت بازی کند، یکی اینکه بی نظمی مطلوبی را درون نمونه های ساخته شده به ازای یک برچسب ثابت لامبدا فراهم کند یکی هم اینکه اگر z را در طول ترین کردن مدل ما کنترل کنیم می توانیم جزئیاتی که لامبدا درون خود ندارد را به z بدهیم تا نمونه هایی واقع گرایانه و متنوع تر تولید کنیم در این روش خصوصیتی از نمونه ها که داخل برچسب لامبدا ثبت نشده اند را کنترل می کنیم.

$|\mathbf{z}\rangle, |\lambda\rangle$
 $G(\theta_G, |\lambda, \mathbf{z}\rangle) = \rho_{\lambda}^G(\theta_G, |\mathbf{z}\rangle)$

حالا به مدار تفکیک کننده علاوه بر پارامتر اصلی اش هم یک کپی بدون تغییر از لامبدا (برای اینکه عملکرد مولد بیشتر وابسته به لامبدا شود) را می دهیم و ماتریس چگالی ساخته شده از یکی از دو مدار R یا G را ورودی می گیرد و باید تصمیم بگیرد که نمونه واقعی هست یا نه.

$D(\theta_D, |\lambda\rangle, R(|\lambda\rangle))$

$D(\theta_D, |\lambda\rangle, G(\theta_G, |\lambda, \mathbf{z}\rangle))$

در این مسئله تفکیک کننده می خواهد خطا را به کمترین مقدار برساند و مولد می خواهد خطا را به بیشترین مقدار برساند و یک بهینه سازی تخصصی داریم همین برای همین ضابطه زیر و ضوابتی که مرتبط با شناسایی شدن نمونه جعلی و حقیقی هست می تواند مناسب باشد.

$V(\theta_G, \theta_D) = \frac{1}{2} \Big(P(D(\theta_D, |\lambda\rangle, R(|\lambda\rangle)) = |\text{real}\rangle) + P(D(\theta_D, |\lambda\rangle, G(\theta_G, |\lambda, \mathbf{z}\rangle)) = |\text{fake}\rangle) \Big)$

در توابع هزینه در *GAN* ها مرسوم است که از توابع *log-likelihood* استفاده شود اما در اینجا ساده تر است که از توابع خطی استفاده شود از آنجایی که هر دو توابع محذب هستند نقاط بهینه شان مشابه است و فرقی در نتیجه نهایی حاصل نمی کند، با فرض اینکه تعدادی متناهی و قابل شمارش برچسب داریم می توان توابع هزینه بر حسب پارامتر های اصلی مولد و تفکیک کننده را به صورت زیر نوشت:

$V(\theta_G, \theta_D) = \frac{1}{\Lambda} \sum_{\lambda=1}^{\Lambda} P(D(\theta_D, |\lambda\rangle, R(|\lambda\rangle)) = |\text{real}\rangle \cap D(\theta_D, |\lambda\rangle, G(\theta_G, |\lambda, \mathbf{z}\rangle)) = |\text{fake}\rangle)$

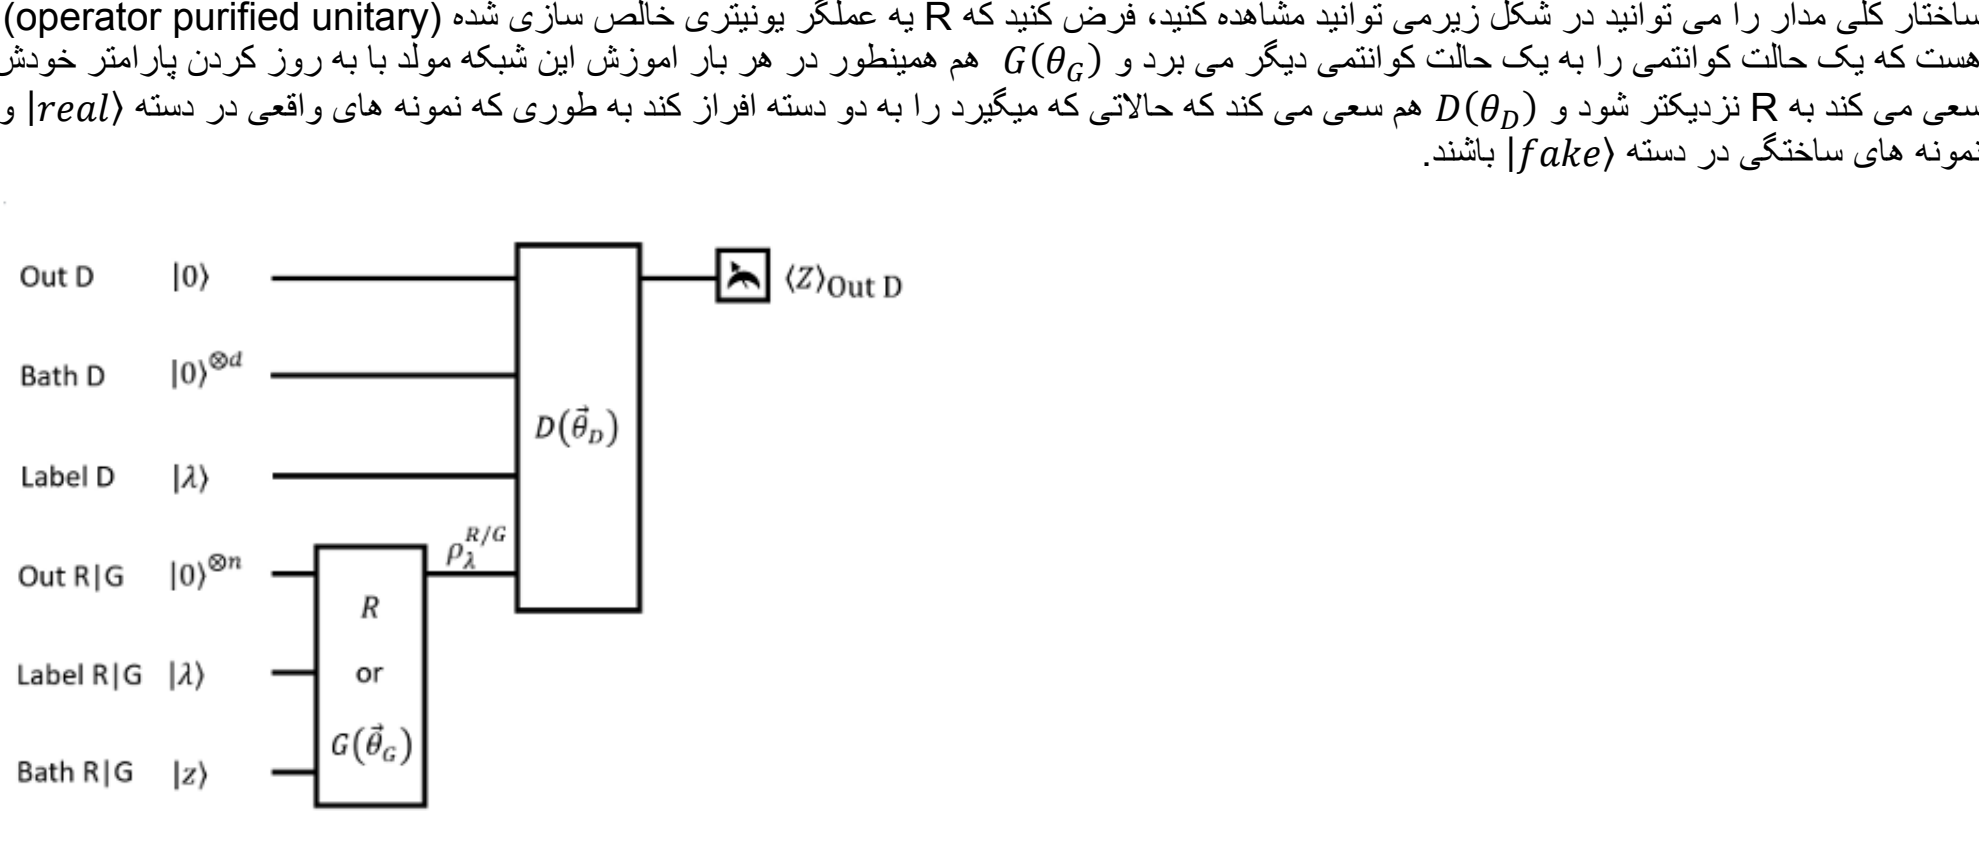
مولد تلاش می کند پارامتری را انتخاب کند که تابع هزینه که رابطه مستقیم با دقت تفکیک کننده دارد را کمینه کند و تفکیک کننده تلاش می کند این مقدار را با به روز رسانی پارامتر مربوط به خود بهینه کند.

$\min_{\theta_G} \max_{\theta_D} V(\theta_G, \theta_D)$

برای پیاده سازی مدار های مربوطه شکل کلی مدار به صورت زیر خواهد بود که رجیستر ها رو به شش بخش تقسیم می کنیم:

- OUT D که شامل یک کیوبیت است و اندازه گیری آن در نهایت خروجی تفکیک کننده را به ما نشان می دهد.
- Bath D که شامل تعدادی کیوبیت برای محاسبات درون تفکیک کننده است.
- Label D که حاوی برچسب است.
- OUT R|G ان کیوبیت که ماتریس چگالی ساخته شده توسط G یا R را در آن ذخیره می کنیم.
- Label R|G شامل برچسب است.
- Bath R|G شامل پارامتر اضافی z است

ساختار کلی مدار را می توانید در شکل زیرمی توانید مشاهده کنید، فرض کنید که R به عملگر یونیتی خالص سازی شده (operator purified unitary) هست که یک حالت کوانتمی را به یک حالت کوانتمی دیگر می برد و $G(\theta_G)$ هم همینطور در هر بار آموزش این شبکه مولد با به روز کردن پارامتر خودش سعی می کند به R نزدیکتر شود و $D(\theta_D)$ هم سعی می کند که حالتی که میگیرد را به دو دسته افراز کند به طوری که نمونه های واقعی در دسته $|\text{real}\rangle$ و نمونه های ساختگی در دسته $|\text{fake}\rangle$ باشند.



$Z \equiv |\text{real}\rangle\langle \text{real}| - |\text{fake}\rangle\langle \text{fake}|$

در ابتدای آموزش مدل از یک وضعیت تصادفی و یا دلخواه مانند زیر شروع می کنیم.

$(\theta_D^0, \theta_G^0) \rightarrow$ initial arbitairy state

$\rho_{\lambda}^0 = (|0\rangle\langle 0|)^{\otimes d+1} \otimes |\lambda\rangle\langle \lambda| \otimes (|0\rangle\langle 0|)^{\otimes n} \otimes |\lambda\rangle\langle \lambda| \otimes |\mathbf{z}\rangle\langle \mathbf{z}|$

ابتدا فرض کنید در حال ساخت یک نمونه یا به وسیله دیتاست یا به وسیله مولد هستیم برای هر دو یک عملگر یونیتی در نظر می گیریم(اس برابر تعداد رجیستر های برچسب است).

$U_R = I^{\otimes (1+d+s)} \otimes R$

$U_G(\theta_G) = I^{\otimes (1+d+s)} \otimes G(\theta_G)$

حال بسته به اینکه کدام یک از بین مولد و دیتاست انتخاب شده باشند بعد از اعمال عملگر ها وضعیت به یکی از دو حالت اول یا دوم تغییر پیدا می کند.

- $\rho_{\lambda}^R = U_R \rho_{\lambda}^0(0) U_R^{\dagger}$
- $\rho_{\lambda}^G(\theta_G, |\mathbf{z}\rangle) = U_G(\theta_G) \rho_{\lambda}^0(\mathbf{z}) U_G(\theta_G)^{\dagger}$

حال نمونه ساخته شده وارد تفکیک کننده می شود عملگر مربوط به تفکیک کننده را نیز اینگونه تعریف می کنیم که برابر ضرب تانسوری ماتریس مربوط به تفکیک کننده و یک ماتریس همانی به ابعاد مشخص شده(m برابر تعداد رجیستر هایی هست که به z مربوط هستند).

$U_D = D(\theta_D) \otimes I^{\otimes m}$

پس از اینکه نمونه به تفکیک کننده رسید عملگر تفکیک کننده را بر آن اعمال می کنیم:

- $\rho_{\lambda}^{DR}(\theta_D) = U_D(\theta_D) \rho_{\lambda}^R U_D(\theta_D)^{\dagger}$
- $\rho_{\lambda}^{DG}(\theta_D, \theta_G, \mathbf{z}) = U_D(\theta_D) \rho_{\lambda}^G(\theta_G, |\mathbf{z}\rangle) U_D(\theta_D)^{\dagger}$

در طول تمرین مدل ها برآی جلو گیری از اینکه وجود یک الگو در برگزیدن مولد و یا دیتاست بایاسی ایجاد بکند از اندازه گیری یک سوپروژیشن مانند زیر استفاده می کنیم که برای مثال 0 نشان دهنده انتخاب کردن مولد و 1 نشان دهنده انتخاب کردن دیتاست می باشد (در مقاله از شانس انتخاب هر دو را برابر گذاشته است).

$|G \text{ or } R\rangle = \sin(\phi) |0\rangle + \cos(\phi) |1\rangle$

بنابر این ما می توانیم تابع هزینه را به این شکل حساب بکنیم، در ادامه روش گرادینن نزولی را برای به روز کردن پارامتر ها پیاده سازی خواهیم کرد.

$V(\theta_G, \theta_D) = \frac{1}{2} + \frac{1}{2\Lambda} \sum_{\lambda=1}^{\Lambda} \Big(\cos^2(\phi) \text{ tr} \Big(Z \rho_{\lambda}^{DR}(\theta_D) \Big) - \sin^2(\phi) \text{ tr} \Big(Z \rho_{\lambda}^{DG}(\theta_D, \theta_G, \mathbf{z}) \Big) \Big)$

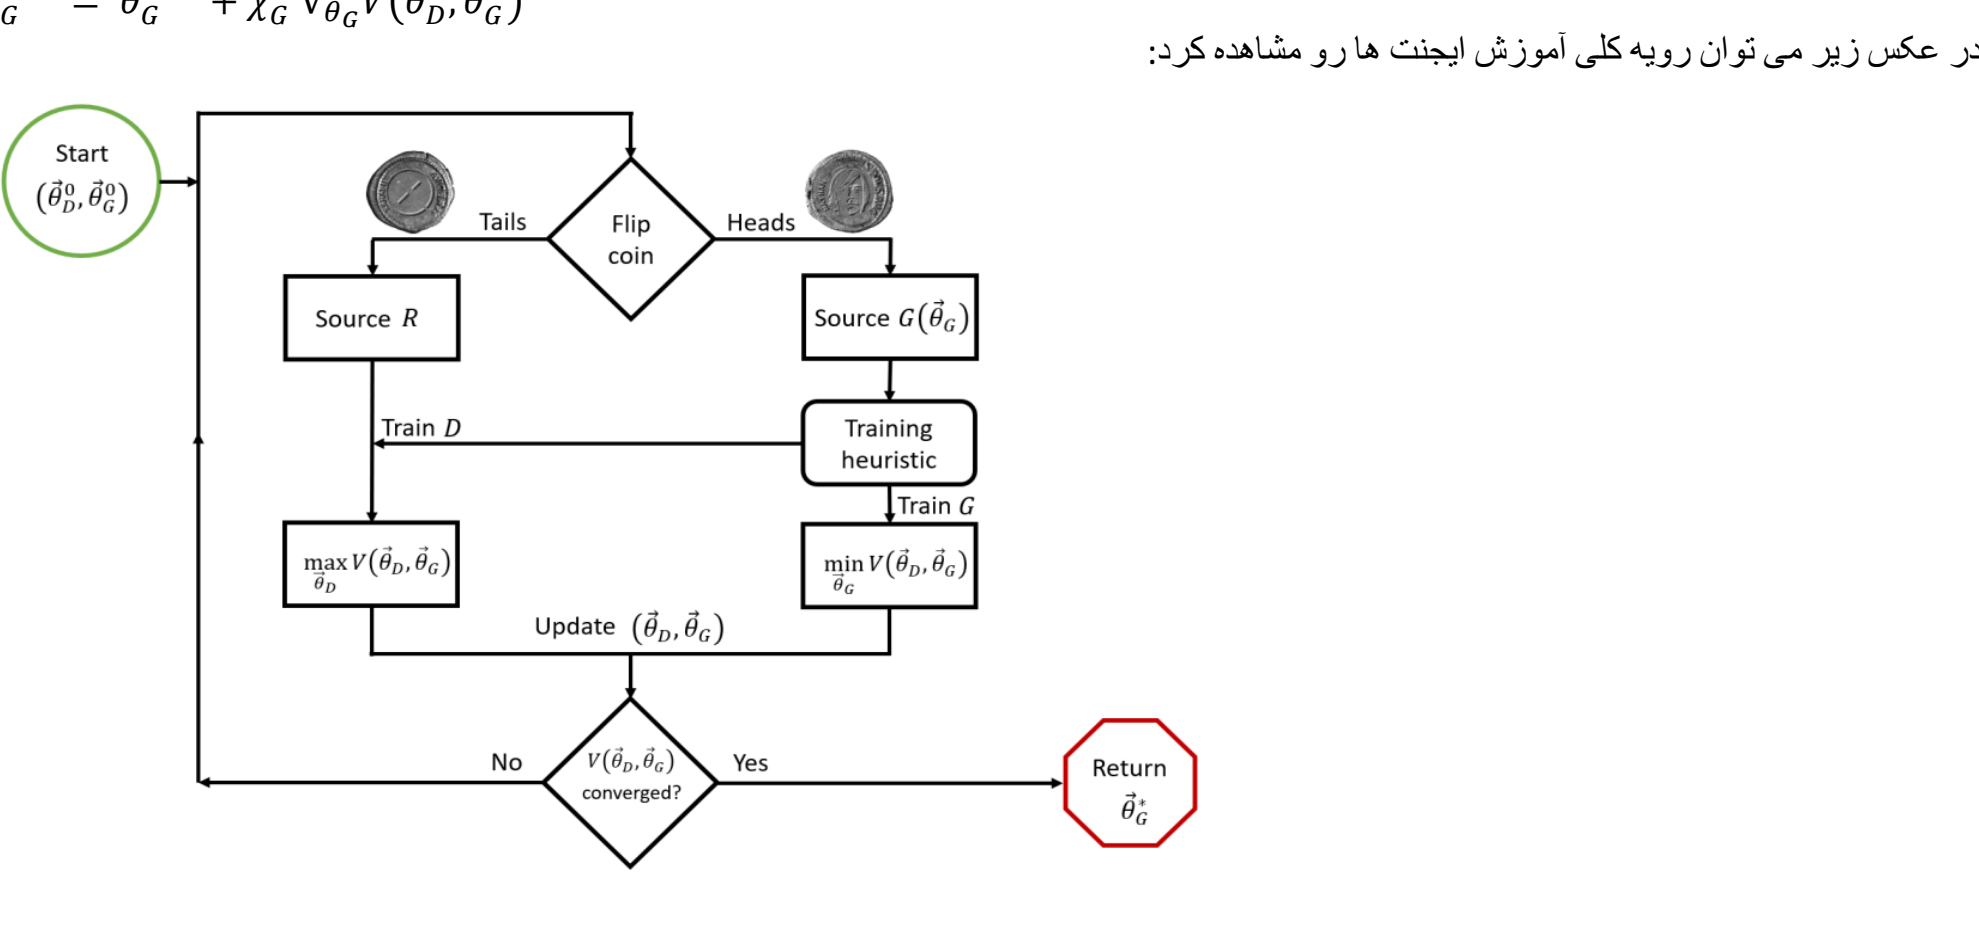
$\Big(G(\theta_G) \text{ and } R \text{ will chosen by a fair coin so } \phi = \frac{\pi}{4} \Big) \rightarrow \min_{\theta_D} \max_{\theta_D} \frac{1}{2} + \frac{1}{4\Lambda} \sum_{\lambda=1}^{\Lambda} \text{ tr} \Big(Z \Big(\rho_{\lambda}^{DR}(\theta_D) - \rho_{\lambda}^{DG}(\theta_D, \theta_G, \mathbf{z}) \Big) \Big)$

در روش گرادینن نزولی بعد از مرحله k-ام پارامتر های تفکیک کننده و مولد را به شکل زیر آپدیت می کنیم (حرف کای یونانی نشان دهنده نرخ یادگیری مولد و یا تفکیک کننده می باشد که در حالت کلی می تواند تابعی از k باشد، چالشی که پیش رو داریم محاسبه ی این گرادینن ها در مدار کوانتمی می باشد.

$\theta_D^{k+1} = \theta_D^{k+1} + \chi_D^k \nabla_{\theta_D} V(\theta_G^k, \theta_D^k)$

$\theta_G^{k+1} = \theta_G^{k+1} + \chi_G^k \nabla_{\theta_G} V(\theta_G^k, \theta_D^k)$

در عکس زیر می توان رویه کلی آموزش ایجنت ها رو مشاهده کرد:



در حالت ایده آل به یک مرحله ای می رسیم که در آن مولد کاملاً با دیتاست برابر می شود و یعنی عبارت 1 که برابر احتمال این است که تفکیک کننده با پارامتر بتواند نمونه های واقعی و نمونه های ساختگی که توسط مولد با پارامتر ساخته شده اند برابر یک دوم باشد در این مرحله هیچ یک از تفکیک کننده و مولد نمی توانند استراتژی خود را بهتر کنند و مدل همگرا می شود و آموزش به پایان می رسد.

$1. P(\text{Success } D(\theta_D)|\theta_G)$

$G(\theta_G^*) = R, P(\text{Success } D(\theta_D^*)|\theta_G^*) = \frac{1}{2} \rightarrow \nabla_{\theta_D} V(\theta_G^*, \theta_D^*) = 0, \nabla_{\theta_G} V(\theta_G^*, \theta_D^*) = 0$

\rightarrow end of the training (model is converged)

اما مقادیر ممکن احتمال این پیشامد با تابع خلوص زیر کران دار می شود:

$C(\theta_G) \equiv \text{tr} \Big(\rho^R \rho^G(\theta_G) \Big)$

$\frac{1}{2} C(\theta_G) \leq P(\text{Success } D(\theta_D)|\theta_G) \leq 1 - \frac{1}{2} C(\theta_G)$

که خود این تابع خلوص هم طبق طبیعت خود دیتاست کران می شود:

r_min کوچک ترین مقدار ویژه ماتریس چگالی ذکر شده هست.

$r_{min} \leq C(\theta_G) \leq \text{tr} \Big((\rho^R)^2 \Big)$

حال از آنجایی که گرادینان ها متناسب با خلوص ماتریس چگالی هستند می توان گرادینان ها را با روش های عددی تخمین زد که برای این امر لازم می شود نمونه های زیادی در اطراف پارامترهای مولد و تفکیک کننده داشته باشیم، ما از یک مدار کوانتمی دیگر علاوه بر این مدار برای بدست آوردن گرادینان ها استفاده می کنیم و بعد از آن با توجه به دسترسی به گرادینان ها پارامتر های مدل را می توانیم در یک کامپیوتر کلاسیک به روز بکنیم.

یک تبدیل خطی یونیتی که توسط یک بردار متشکل از تعدادی متناهی عضو پارامتر شده را در نظر بگیرید:

$U(\theta) \equiv U_N(\theta_N) U_{N-1}(\theta_{N-1}) \dots U_2(\theta_2) U_1(\theta_1)$

نماد گذاری زیر را چون در محاسبات پیش رو استفاده می شود معرفی می کنم معادلتش در مدار هم به تصویر کشیده شده:

$U_{k:l} \equiv U_k(\theta_k) U_{k-1}(\theta_{k-1}) \dots U_{l+1}(\theta_{l+1}) U_l(\theta_l)$

$U_{k:l} = U_l(\theta_l) U_{l+1}(\theta_{l+1}) \dots U_{k-1}(\theta_{k-1}) U_k(\theta_k)$

و همچنین طبق خواص ماتریس های یونیتی داریم:

$U_{k:l}^{\dagger} \equiv U_l^{\dagger}(\theta_l) U_{l+1}^{\dagger}(\theta_{l+1}) \dots U_{k-1}^{\dagger}(\theta_{k-1}) U_k^{\dagger}(\theta_k)$

فرض کنید هر عضو توسط یک ماتریس همیلتونی به h ساخته شده پس عملگر ما در واقع برابر با عبارت زیر است که تمام این نتایج را منجر می شود

$U_j(\theta_j) = e^{-\frac{i}{2} \theta_j h_j}, \quad U_j^{\dagger}(\theta_j) = e^{\frac{i}{2} \theta_j h_j}$


$\frac{\partial}{\partial \theta_j} U_j(\theta_j) = -\frac{i}{2} h_j U_j(\theta_j), \quad \frac{\partial}{\partial \theta_j} U_j^{\dagger}(\theta_j) = \frac{i}{2} h_j U_j^{\dagger}(\theta_j)$

$\frac{\partial}{\partial \theta_j} U(\theta) = -\frac{i}{2} U_{N:j+1} h_j U_{j+1:N}, \quad \frac{\partial}{\partial \theta_j} U^{\dagger}(\theta) = \frac{i}{2} U_{1:j}^{\dagger} h_j U_{j+1:N}$

اگر یک حالت اولیه را به کای کیوبیت ها تعریف بکنیم امید ریاضی آیزورویل برحسب تتا می شود:

$\langle P(\theta) \rangle = \text{tr}(\rho_0 U^{\dagger}(\theta) P U(\theta))$

حال با استفاده از دانسته های مان می توانیم گرادینان امید ریاضی آیزورویل را به کمک مدار زیر حساب کنیم.



برگردیم به مسئله اصلی حالا که این ساختار چندلایه U را توانستیم گرادینان بگیریم می توانیم فرض کنیم که ساختار مولد و تفکیک کننده هم مشابه این ساختار است مشابه زیر:

$D(\theta_D) = D_{N_D:1}(\theta_{D_D}), G(\theta_G) = G_{N_G:1}(\theta_G)$

بنابر این با این مدار می توانیم مولد و تفکیک کننده را بدین شکل پیاده کنیم و گرادینان ها رو هم می توانیم با پیدا کنیم و از یک کامپیوتر کلاسیک برای به روز رسانی پارامتر ها استفاده کنیم:

